



**Instituto Tecnológico Superior de
Ciudad Constitución.**

**INGENIERÍA EN SISTEMAS
COMPUTACIONALES.**

Ciencia de datos

“Practica ETL part1.1”

Instructor: Isaac Felipe Garcia Lopez

Grupo: 8SM

Alumno: Luis Manuel Muñoz Lizarraga

Fecha de entrega: 26 - 05 - 2026

Cd. Constitución, B.C.S.

Introducción

En esta práctica se desarrolló un proceso ETL (Extract, Transform, Load) utilizando Python. El objetivo principal fue extraer datos del archivo members.csv, transformar y evaluar la columna correspondiente a los números de teléfono utilizando Expresiones Regulares (RegEx), y finalmente cargar los resultados en una base de datos local usando SQLite3.

Resultados del Análisis

Tras procesar exitosamente el conjunto de datos, se evaluaron un total de 5000 registros. Los resultados obtenidos de las validaciones telefónicas fueron los siguientes:

- **Números que contienen el código '+62':** 2215 (44.3%)
- **Números que inician con corchetes y un guion '[]-':** 0 (0.0%)
- **Números que contienen espacios en blanco:** 3580 (71.6%)

Técnicas y Patrones RegEx Utilizados

Para llevar a cabo la limpieza y análisis de los datos, se implementó el módulo nativo re de Python. A continuación, se explican detalladamente los patrones construidos:

1. Patrón para encontrar "+62" (r'\+62'):

Explicación: El símbolo + es un metacaracter reservado en RegEx que significa "una o más ocurrencias". Para buscar el carácter literal de suma, se utilizó la barra invertida \ como mecanismo de escape. Esto le indica al motor que busque exactamente el texto "+62", el cual corresponde a códigos telefónicos internacionales (por ejemplo, de Indonesia).

2. Patrón para encontrar corchetes al inicio seguidos de un guion (r'^\[.*?\]-'):

Explicación:

- ^: Ancla que indica que la coincidencia debe darse estrictamente al inicio de la cadena.
- \[y \]: Escapan los corchetes para que se busquen como caracteres literales.
- .*?: Busca cualquier carácter interno entre los corchetes de forma "perezosa" (no codiciosa), deteniéndose en el primer corchete de cierre.
- -: Busca el carácter literal del guion justo después del corchete de cierre.

3. Patrón para encontrar espacios vacíos (r'\s+')

Explicación:

La secuencia especial \s busca cualquier carácter de espacio en blanco (incluyendo espacios comunes, tabulaciones o saltos de línea). El modificador + indica que queremos encontrar uno o más espacios continuos.

Proceso de Carga (Load) con SQLite3

La información leída del CSV fue procesada fila por fila. Para cada registro, las funciones de RegEx evaluaban las coincidencias devolviendo valores booleanos. Durante la carga hacia SQLite3, estos valores se convirtieron a enteros (1 y 0) y se almacenaron en las nuevas columnas: tiene_plus_62, tiene_corchetes_guion y tiene_espacios. Finalmente, se utilizó la instrucción INSERT OR REPLACE INTO sobre la tabla members en la base de datos members.db, garantizando que no existan duplicados usando el participant_id como llave primaria.